

信号估值理论

赵丰

2018 年 4 月 13 日

1. Bayes 估值

代价函数 $C(\hat{\theta}, \theta) = C(\tilde{\theta})$, 其中 $\tilde{\theta} = \hat{\theta} - \theta$ 。平均风险

$$\bar{R} = \int_{\mathcal{Z}} \int_{\Theta} C(\tilde{\theta}) d\theta dz$$

记 $\bar{R}(z) = \int_{\Theta} C(\tilde{\theta}) p(\theta|z) d\theta$, 称为“给定 z 时的条件风险”。则 $\bar{R} = \int_{\mathcal{Z}} \bar{R}(z) p(z) dz$ 。Bayes 估值等价于求解 $\underset{\hat{\theta}}{\operatorname{argmin}} \bar{R}(z)$

2. 常见的代价函数

(1) 平方误差代价: $C(\tilde{\theta}) = \tilde{\theta}^2, \hat{\theta}_{\text{ms}} = \int_{\Theta} \theta p(\theta|z) d\theta = \mathbb{E}[\theta|z], \hat{\theta}_{\text{ms}}$ 被称为后验均值。

(2) 绝对误差代价: $C(\tilde{\theta}) = |\tilde{\theta}|, \hat{\theta}_{\text{abs}}$ 满足 $\int_{-\infty}^{\hat{\theta}_{\text{abs}}} p(\theta|z) d\theta = \int_{\hat{\theta}_{\text{abs}}}^{+\infty} p(\theta|z) d\theta$, $\hat{\theta}_{\text{abs}}$ 被称为后验中值。

(3) 均匀误差代价:

$$C(\tilde{\theta}) = \begin{cases} 0, & |\tilde{\theta}| \leq \frac{\Delta}{2} \\ 1, & |\tilde{\theta}| > \frac{\Delta}{2} \end{cases}$$

此时的条件风险为:

$$\bar{R}(z) = 1 - \int_{\hat{\theta} - \frac{\Delta}{2}}^{\hat{\theta} + \frac{\Delta}{2}} p(\theta|z) d\theta$$

当 Δ 很小时, 使得条件风险 $\bar{R}(z)$ 最小有: $\hat{\theta}_{\text{unf}} \approx \hat{\theta}_{\text{map}}$, 相当于后验概率密度的众数。

(4) 对称下凸代价

若代价函数满足

$$(a) C(\tilde{\theta}) = C(-\tilde{\theta})$$

$$(b) C(b\theta_1 + (1-b)\theta_2) \leq bC(\theta_1) + (1-b)C(\theta_2), \forall b \in (0, 1)$$

并且后验密度函数满足

$$(c) p(\theta|z) = p(2\hat{\theta}_{\text{ms}} - \theta|z)$$

$$\text{则 } \hat{\theta}_{\text{ms}} = \underset{\hat{\theta}}{\operatorname{argmin}} \bar{R}(z)$$

证明.

$$\bar{R}(z) = \int_{\mathbb{R}} C(\theta - \hat{\theta}) p(\theta|z) d\theta \quad (1)$$

$$\begin{aligned} &= \int_{\mathbb{R}} C(\theta - \hat{\theta}) p(2\hat{\theta}_{\text{ms}} - \theta|z) d\theta \\ &= \int_{\mathbb{R}} C(2\hat{\theta}_{\text{ms}} - \theta - \hat{\theta}) p(\theta|z) d\theta \\ &= \int_{\mathbb{R}} C(-2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}) p(\theta|z) d\theta \end{aligned} \quad (2)$$

对 (1) 和 (2) 作平均得：

$$\begin{aligned} \bar{R}(z) &= \int_{\mathbb{R}} \frac{1}{2} \left(C(\theta - \hat{\theta}) + C(-2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}) \right) p(\theta|z) d\theta \\ &\geq \int_{\mathbb{R}} C(\theta - \hat{\theta}_{\text{ms}}) p(\theta|z) d\theta \end{aligned}$$

上式右端和 $\hat{\theta}$ 无关，当 $\theta - \hat{\theta} = -2\hat{\theta}_{\text{ms}} + \theta + \hat{\theta}$ 时不等式成立，即 $\hat{\theta} = \hat{\theta}_{\text{ms}}$ □

(5) 对称非下凸代价

3. 常见估值方式

(a) 极大极小估值：先验未知，寻找先验概率 $p(\theta)$ 的最不利分布，再确定 Bayes 估值。

(b) 最大后验估值：代价函数未知，求解最大后验方程，

$$\left[\frac{\partial \ln p(z|\theta)}{\partial \theta} + \frac{\partial p(\theta)}{\partial \theta} \right] \Big|_{\theta=\hat{\theta}_{\text{map}}} = 0 \quad (3)$$

(c) 最大似然估值：先验和代价函数均未知 $\hat{\theta}_{\text{ML}} = \max_{\theta} p(z|\theta)$

4. 估计量的性质

(a) 无偏估计量

对于随机参量 θ , 无偏性要求 $\mathbb{E}[\hat{\theta}] = \mathbb{E}[\theta]$ 即 $\int_{\Theta} \int_{\mathcal{Z}} \hat{\theta} p(z, \theta) dz d\theta = \int_{\mathcal{Z}} \hat{\theta} p(z) dz$

(b) 一致估计量

基于 N 个观测值组成的观测矢量 \mathbf{z}_N 作估值: $\hat{\theta}(\mathbf{z}_N)$ 是参数 θ 的一致估计量, 当其满足

$$\lim_{N \rightarrow \infty} \Pr(|\hat{\theta}(\mathbf{z}_N) - \theta| < \epsilon) = 1, \forall \epsilon > 0$$

(c) 充分统计量: $\hat{\theta}(z)$ 是参数 θ 的充分统计量, 当 $p(z|\theta) = p(\hat{\theta}(z)|\theta)h(z)$

(d) 有效 (efficient) 统计量: 具有最小方差的无偏估计量。

5. C-R 不等式

	非随机	随机
等价形式	$\mathbb{E}[(\hat{\theta} - \theta)^2 \theta] \geq 1 / \mathbb{E} \left[\left(\frac{\partial \ln p(z \theta)}{\partial \theta} \right)^2 \theta \right]$ $\mathbb{E} \left[\left(\frac{\partial \ln p(z \theta)}{\partial \theta} \right)^2 \theta \right] = -\mathbb{E} \left[\frac{\partial^2 \ln p(z \theta)}{\partial \theta^2} \right]$	$\mathbb{E}[(\hat{\theta} - \theta)^2] \geq 1 / \mathbb{E} \left[\left(\frac{\partial \ln p(z, \theta)}{\partial \theta} \right)^2 \right]$ $\mathbb{E} \left[\left(\frac{\partial \ln p(z, \theta)}{\partial \theta} \right)^2 \right] = -\mathbb{E} \left[\frac{\partial^2 \ln p(z, \theta)}{\partial \theta^2} \right]$
存在条件	$\frac{\partial p(z \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K(\theta)$	$\frac{\partial p(z, \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K$
有效估值存在	有效估值就是最大似然估值	有效估值就是 $\hat{\theta}_{\text{ms}}$ 或 $\hat{\theta}_{\text{map}}$

表 1: 随机参量和非随机参量的对比

在随机参量的情况下, 有 $\frac{\partial p(z, \theta)}{\partial \theta} = \frac{\partial p(\theta|z)}{\partial \theta}$ 。若有效估值存在, 则后验概率密度满足方程 $\frac{\partial p(z, \theta)}{\partial \theta} = (\hat{\theta} - \theta) \cdot K$, 从而解出 $p(\theta|z) = D \exp \left(-\frac{K}{2} (\theta - \hat{\theta})^2 \right)$, 即后验分布是高斯分布。反之, 若后验分布是高斯分布, 也满足有效估值存在性方程。所以对于随机参量, 有效估值存在当且仅当后验分布是高斯分布。

6. 白高斯信道中单参量信号的估值

假设观测信号 $z(t) = s(t, \theta) + n(t), 0 \leq t \leq T$

(1) θ 是未知的非随机参量时, 求 $\hat{\theta}_{\text{ML}}$

采用 K-L 展开求极限的方法,

将 $z(t)$ 在归一化的正交基函数 $\{g_k(t)\}$ 上作 K-L 展开: $z(t) = \sum_{k=1}^{\infty} z_k g_k(t)$ 其中, $z_k = \int_0^T z(t) g_k(t) dt = \int_0^T [s(t, \theta) + n(t)] g_k(t) dt =$

$s_k(\theta) + n_k$ 由于 n_k 为高斯分布, 故 z_k 亦为高斯分布, 且有

$$\begin{aligned}\mathbb{E}[z_k] &= s_k(\theta) \\ \text{Var}[z_k] &= \text{Var}[n_k] = \frac{N_0}{2} \\ \text{Cov}(z_k, z_l) &= \frac{N_0}{2} \delta_{kl}\end{aligned}$$

对观测矢量 $\mathbf{z}_N = (z_1, z_2, \dots, z_N)$ 而言, 联合概率密度函数为:

$$p(\mathbf{z}|\theta) = \prod_{k=1}^N \frac{1}{\sqrt{2\pi N_0/2}} \exp\left(-\frac{(z_k - s_k(\theta))^2}{N_0}\right) = \left(\frac{1}{\sqrt{\pi N_0}}\right)^N \exp\left(-\frac{1}{N_0} \sum_{k=1}^N (z_k - s_k(\theta))^2\right)$$

因此 $\frac{\partial \ln p(\mathbf{z}_N|\theta)}{\partial \theta} = \frac{2}{N_0} \sum_{k=1}^N (z_k - s_k(\theta)) \frac{\partial s_k(\theta)}{\partial \theta}$ 取极限得:

$$\frac{\partial p(z(t)|\theta)}{\partial \theta} = \lim_{N \rightarrow \infty} \frac{\partial \ln p(\mathbf{z}|\theta)}{\partial \theta} = \frac{2}{N_0} \sum_{k=1}^{\infty} (z_k - s_k(\theta)) \frac{\partial s_k(\theta)}{\partial \theta}$$

又根据 z_k 和 $s_k(\theta)$ 的 K-L 展开式和公式 $\sum_{k=1}^{\infty} g_k(t)g_k(\tau) = \delta(t - \tau)$, 我们有:

$$\begin{aligned}\sum_{k=1}^{\infty} z_k \frac{\partial s_k(\theta)}{\partial \theta} &= \sum_{k=1}^{\infty} \int_0^T \int_0^T z(t)g_k(t) \frac{\partial s(\tau, \theta)}{\partial \tau} g_k(\tau) dt d\tau \\ &= \int_0^T z(t) \frac{\partial s(t, \theta)}{\partial \theta} dt\end{aligned}$$

同理 $\sum_{k=1}^{\infty} s_k \frac{\partial s_k(\theta)}{\partial \theta} = \int_0^T s(t) \frac{\partial s(t, \theta)}{\partial \theta} dt$, 从而有:

$$\frac{\partial p(z(t)|\theta)}{\partial \theta} = \frac{2}{N_0} \int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt \quad (4)$$

由此可得最大似然方程:

$$\int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt \Big|_{\theta=\hat{\theta}_{\text{ML}}} = 0 \quad (5)$$

对上式求导可得 C-R 界为 $\frac{N_0/2}{\int_0^T \left(\frac{\partial s(t, \theta)}{\partial \theta}\right)^2 dt}$

(2) 信号幅度的估值

此时, 信号 $s(t, A) = As(t)$, 其中 A 是待估值的非随机参量。

由(4)式等于 0 得到:

$$\hat{A}_{\text{ML}} = \frac{\int_0^T z(t)s(t)dt}{\int_0^T s^2(t)dt}$$

不妨令 $\int_0^T s^2(t)dt = 1$ (信号能量归一化), 易验证 \hat{A}_{ML} 具有性质:

(a) 无偏性

(b) 方差为 $\frac{N_0}{2}$, 等于 C-R 界, 因此是有效估值。

(3) 信号相位的估值

此时, 信号 $s(t, \theta) = A \sin(\omega_0 t + \theta)$, $0 \leq t \leq T$, 其中 θ 是待估值的非随机参量, 而 A 和 ω_0 是已知常数, 假定 ωT 是 π 的整数倍。由(4)式等于 0 得到:

$$\hat{\theta}_{\text{ML}} = \arctan \left(\frac{\int_0^T z(t) \cos \omega_0 t dt}{\int_0^T z(t) \sin \omega_0 t dt} \right)$$

当信噪比足够大时, $n(t)/A$ 是小量, 将上式中 \arctan 在 $\tan(\theta)$ 处 Taylor 展开, 得到

$$\hat{\theta}_{\text{ML}} \approx \theta + \frac{2}{AT} \int_0^T \cos(\omega t + \theta) n(t) dt$$

因此 $\hat{\theta}_{\text{ML}}$ 近似为均值为 θ (无偏), 方差为 $\frac{N_0}{A^2 T}$ (有效) 的高斯分布。

(4) 信号频率的估值

此时, 信号 $s(t, \omega) = A \sin(\omega t + \theta)$, $0 \leq t \leq T$, 其中 ω 是待估值的非随机参量, 而 A 是已知常数, θ 是杂散参量。可以求出信号频率的最大似然估值为

$$\hat{\omega}_{\text{ML}} = \underset{\omega}{\text{argmin}} \left(\int_0^T z(t) \cos \omega t dt \right)^2 + \left(\int_0^T z(t) \sin \omega t dt \right)^2$$

(5) θ 为已知先验概率的随机参量时, 求 $\hat{\theta}_{\text{map}}$

首先, 我们通过最大后验方程(3)式来求其估值: 第一项已经由前面(4)求出, 最大后验方程可重写为

$$\left[\frac{2}{N_0} \int_0^T (z(t) - s(t, \theta)) \frac{\partial s(t, \theta)}{\partial \theta} dt + \frac{\partial p(\theta)}{\partial \theta} \right] \Big|_{\theta=\hat{\theta}_{\text{map}}} = 0 \quad (6)$$

在 (2) 中, 若 $A \sim N(0, \sigma_A^2)$, 根据(6) 可得信号的幅度估值为

$$\hat{A}_{\text{map}} = \frac{\int_0^T z(t) s(t) dt}{\int_0^T s^2(t) dt + \frac{N_0}{2\sigma_A^2}}$$

\hat{A}_{ML} 具有性质:

(a) 无偏性: $\mathbb{E}[A] = 0, \mathbb{E}[\hat{A}_{\text{map}}] = 0$

(b) 利用随机参数的 C-R 界的公式, $\mathbb{E}[(\hat{A}_{\text{map}} - A)^2]$ 为 $1/[\frac{2}{N_0} \int_0^T s^2(t)dt + \frac{1}{\sigma_A^2}]$ 等于 C-R 界, 因此是有效估值。

7. 色高斯信道非随机参量的估值

观测方程 $z(t) = s(t, \theta) + n(t), 0 \leq t \leq T$, 其中 $n(t)$ 为色高斯平稳噪声, 其相关函数记为 $R_n(t - \tau)$ 。沿用信号检测理论中的 K-L 展开法, $z(t) = \sum_{k=1}^{\infty} z_k g_k(t)$, 系数 $\{z_k\}$ 互不相关, 且 $z_k \sim N(s_k, \lambda_k)$ 。似然函数为:

$$p(z(t)) = \prod_{k=1}^{\infty} \frac{1}{\sqrt{2\pi\lambda_k}} \exp\left(-\frac{(z_k - s_k)^2}{2\lambda_k}\right)$$

取其对数形式, 有:

$$\ln p(z(t)) = C - \sum_{k=1}^{\infty} \frac{z_k^2}{2\lambda_k} + \sum_{k=1}^{\infty} \frac{z_k s_k}{\lambda_k} - \sum_{k=1}^{\infty} \frac{s_k^2}{2\lambda_k} \quad (7)$$

其中 C 为与信号参量不相关的部分项。而在信号估计理论一节已经推导出

$$\sum_{k=1}^{\infty} \frac{z_k s_k}{\lambda_k} = \int_0^T z(t) h(t) dt \quad (8a)$$

$$\sum_{k=1}^{\infty} \frac{s_k^2}{2\lambda_k} = \frac{1}{2} \int_0^T s(t, \theta) h(t) dt \quad (8b)$$

其中 $h(t) = \sum_{k=1}^{\infty} \frac{s_k g_k(t)}{\lambda_k}$, 为将 $h(t)$ 表示成积分的形式, 引入反核函数 $R_n^{-1}(t - \tau)$, 相对于 $R_n(t - \tau)$, 我们有

$$R_n(t - \tau) = \sum_{k=1}^{\infty} \lambda_k g_k(t) g_k(\tau) \quad (9a)$$

$$R_n^{-1}(t - \tau) = \sum_{k=1}^{\infty} \frac{1}{\lambda_k} g_k(t) g_k(\tau) \quad (9b)$$

满足 $\int_0^T R_n^{-1}(t - \tau) R_n(\tau - \mu) d\tau = \delta(t - u)$ 针对(9b), 两边乘以 $s(\tau, \theta)$ 对 τ 积分得: $h(t) = \int_0^T s(\tau, \theta) R_n^{-1}(t - \tau) d\tau$ 利用反核函数的表达式:

$$\begin{aligned} \sum_{k=1}^{\infty} \frac{z_k^2}{2\lambda_k} &= \frac{1}{2} \int_0^T \int_0^T z(t) z(\tau) \sum_{k=1}^{\infty} \frac{g_k(t) g_k(\tau)}{\lambda_k} dt d\tau \\ &= \frac{1}{2} \int_0^T \int_0^T z(t) z(\tau) R_n^{-1}(t, \tau) dt d\tau \end{aligned}$$

因此(7)化为：

$$\begin{aligned}
\ln p(z(t)) &= C - \frac{1}{2} \int_0^T \int_0^T [z(t)z(\tau) - 2z(t)s(\tau, \theta) + s(t, \theta)s(\tau, \theta)] R_n^{-1}(t - \tau) dt d\tau \\
&= C - \frac{1}{2} \int_0^T \int_0^T [z(t) - s(t, \theta)] R_n^{-1}(t - \tau) [z(\tau) - s(\tau, \theta)] dt d\tau \\
\frac{\partial \ln p(z(t)|\theta)}{\partial \theta} &= \int_0^T \int_0^T [z(t) - s(t, \theta)] R_n^{-1}(t - \tau) \frac{\partial s(\tau, \theta)}{\partial \theta} dt d\tau \\
&= \int_0^T (z(t) - s(t, \theta)) \frac{\partial h(t, \theta)}{\partial \theta} dt
\end{aligned}$$

利用极大似然法可以写出似然方程为

$$\int_0^T (z(t) - s(t, \theta)) \frac{\partial h(t, \theta)}{\partial \theta} dt \Big|_{\theta=\hat{\theta}_{\text{ML}}} = 0 \quad (10)$$

对比(5)式和(10)式可以发现，色高斯信道的 ML 估计中求偏导用 $h(t, \theta)$ 代替了 $s(t, \theta)$ 。当 $\lambda_k = \frac{N_0}{2}$ 时， $R_n(t - \tau) = \frac{N_0}{2} \delta(t - \tau)$ ， $R_n^{-1}(t - \tau) = \frac{2}{N_0} \delta(t - \tau)$ ， $h(t, \theta) = \frac{2}{N_0} s(t, \theta)$

另外不难求出估值的 C-R 界为 $1 / \int_0^T \frac{\partial s(t, \theta)}{\partial \theta} \frac{\partial h(t, \theta)}{\partial \theta} dt$

例：信号振幅估计 $s(t, A) = As(t)$ ，由(10)式解得：

$$\hat{A}_{\text{ML}} = \frac{\int_0^T z(t) \tilde{h}(t) dt}{\int_0^T s(t) \tilde{h}(t) dt}$$

其中 $\tilde{h}(t) = \int_0^T s(\tau) R_n^{-1}(t - \tau) d\tau$

8. 多参量估值：可由单参数估值形式推广

9. 线性最小均方估值

放宽对信号已知知识的要求，假设

(a) 对信号的统计知识只知道信号参量 θ 和观测值 z 的一、二阶矩：

$$\mathbb{E}[\theta], \mathbb{E}[z], \text{Var}[\theta], \text{Var}[z], \text{Cov}[\theta, z]$$

(b) 估值是观测值的线性组合 $\hat{\theta} = \mathbf{A}z + \mathbf{b}$

MSE 估值准则为： $\min_{\mathbf{A}, \mathbf{b}} \mathbb{E}[(\hat{\theta} - \theta)^T (\hat{\theta} - \theta)]$ ，其中 \mathbb{E} 是关于 θ, z 联合分布的期望。

首先说明最小均方估值是无偏的, 即 $\mathbb{E}[\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}] = \mathbf{0}$, 反设 $\mathbb{E}[\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}] = \mathbf{b} \neq \mathbf{0}$ 构造 $\hat{\boldsymbol{\theta}}' = \hat{\boldsymbol{\theta}} - \mathbf{b}$, 有:

$$\begin{aligned}\mathbb{E}[(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})] &= \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})] - \mathbf{b}^T \mathbf{b} \\ &< \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})]\end{aligned}$$

因此 $\mathbf{b} = \mathbb{E}[\boldsymbol{\theta}] - \mathbf{A}\mathbb{E}[\mathbf{z}]$ 其次说明最小均方估值的误差与观测 \mathbf{z} 正交, 反设 $\mathbb{E}[(\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta})\mathbf{z}^T] = \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}} \neq \mathbf{0}_{M \times N}$, 其中 $\boldsymbol{\theta}$ 是 M 维向量, \mathbf{z} 是 N 维向量。构造 $\hat{\boldsymbol{\theta}}' = \hat{\boldsymbol{\theta}} - \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}}\text{Var}^{-1}[\mathbf{z}](\mathbf{z} - \mathbb{E}[\mathbf{z}])$, (不妨设 $M = 1$, 否则分别考虑 $\boldsymbol{\theta}$ 的各分量) 有:

$$\begin{aligned}\mathbb{E}[(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}}' - \boldsymbol{\theta})] &= \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})] - \boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}}\text{Var}^{-1}[\mathbf{z}]\boldsymbol{\Lambda}_{\mathbf{e}\mathbf{z}} \\ &< \mathbb{E}[(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^T(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})]\end{aligned}$$

因此 $\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta}$ 与 $\mathbf{z} - \mathbb{E}[\mathbf{z}]$ 正交, 已有 $\hat{\boldsymbol{\theta}}_{\text{LMS}} = \mathbf{A}(\mathbf{z} - \mathbb{E}[\mathbf{z}]) + \mathbb{E}[\boldsymbol{\theta}]$ 。由 $\mathbb{E}[(\hat{\boldsymbol{\theta}}_{\text{LMS}} - \boldsymbol{\theta})(\mathbf{z} - \mathbb{E}[\mathbf{z}])^T] = \mathbf{0}$ 得 $\mathbf{A} = \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}]$ 因此

$$\hat{\boldsymbol{\theta}}_{\text{LMS}} = \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}](\mathbf{z} - \mathbb{E}[\mathbf{z}]) + \mathbb{E}[\boldsymbol{\theta}] \quad (11)$$

线性最小均方估值的误差矩阵为:

$$\begin{aligned}\text{Var}[\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta}] &= \mathbb{E}[(\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta})(\boldsymbol{\theta}_{\text{LMS}} - \boldsymbol{\theta})^T] \\ &= \text{Var}[\boldsymbol{\theta}] - \text{Cov}[\boldsymbol{\theta}, \mathbf{z}]\text{Var}^{-1}[\mathbf{z}]\text{Cov}[\mathbf{z}, \boldsymbol{\theta}]\end{aligned}$$

10. 最小二乘估值: 仅有观测, 无先验

假定观测模型为:

$$\mathbf{z} = \mathbf{C}\boldsymbol{\theta} + \mathbf{n} \quad (12)$$

其中 \mathbf{n} 是观测噪声, $\boldsymbol{\theta}$ 是 M 维向量, \mathbf{z} 是 N 维向量, $N > M$ 。最小二乘估值准则为:

$$\min_{\hat{\boldsymbol{\theta}}=\hat{\boldsymbol{\theta}}_{\text{LS}}} (\mathbf{z} - \mathbf{C}\hat{\boldsymbol{\theta}})^T(\mathbf{z} - \mathbf{C}\hat{\boldsymbol{\theta}}) \quad (13)$$

解得

$$\hat{\boldsymbol{\theta}}_{\text{LS}} = (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \mathbf{z} \quad (14a)$$

$$= \boldsymbol{\theta} + (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \mathbf{n} \quad (14b)$$

因为 $\mathbb{E}[\mathbf{n}] = \mathbf{0}$, 所以最小二乘估值对给定的观测模型是无偏估计。最小二乘估值的方差矩阵为

$$\text{Var}[\boldsymbol{\theta}_{\text{LS}} - \boldsymbol{\theta}] = (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \text{Var}[\mathbf{n}] \mathbf{C} (\mathbf{C}^T \mathbf{C})^{-1}$$

11. 加权最小二乘估值 (LSW) 对观测模型 $\mathbf{z} = \mathbf{C}\boldsymbol{\theta} + \mathbf{n}$ 引入新的目标函数 $(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})^T \mathbf{W}(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})$, 其中 \mathbf{W} 是对称正定的加权矩阵, 加权最小二乘估值准则可描述为:

$$\min_{\boldsymbol{\theta}=\boldsymbol{\theta}_{\text{LSW}}} (\mathbf{z} - \mathbf{C}\boldsymbol{\theta})^T \mathbf{W}(\mathbf{z} - \mathbf{C}\boldsymbol{\theta})$$

从而得到加权最小二乘估值为: $\boldsymbol{\theta}_{\text{LSW}} = (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1} \mathbf{C}^T \mathbf{W} \mathbf{z}$ 估值的方差矩阵为

$$\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] = (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1} \mathbf{C}^T \mathbf{W} \text{Var}[\mathbf{n}] \mathbf{W} \mathbf{C} (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1}$$

下面求方差矩阵的下限:

设 $\text{Var}[\mathbf{n}] = \mathbf{H}^T \mathbf{H}$, $\mathbf{B} = \mathbf{H} \mathbf{W} \mathbf{C} (\mathbf{C}^T \mathbf{W} \mathbf{C})^{-1}$, 则 $\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] = \mathbf{B}^T \mathbf{B}$, 取 $\mathbf{A} = \mathbf{C}^T \mathbf{H}^{-1}$, 则 $\mathbf{A} \mathbf{B} = \mathbf{I}$

使用矩阵不等式

$$\mathbf{B}^T \mathbf{B} \succcurlyeq (\mathbf{A} \mathbf{B})^T (\mathbf{A} \mathbf{A}^T)^{-1} (\mathbf{A} \mathbf{B}) \quad (15)$$

证明. 设 \mathbf{x} 是与 \mathbf{B} 的列数相同的列向量。只需证明 $\mathbf{x}^T \mathbf{B}^T \mathbf{B} \mathbf{x} \geq \mathbf{x}^T (\mathbf{A} \mathbf{B})^T (\mathbf{A} \mathbf{A}^T)^{-1} (\mathbf{A} \mathbf{B}) \mathbf{x}$, 则只需证明 $\mathbf{I} - \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$ 半正定。设 \mathbf{y} 是 $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$ 的特征向量, 特征值为 σ , 则 $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A} \mathbf{y} = \sigma \mathbf{y}$, 等式两端左乘以 $\mathbf{A} \Rightarrow \mathbf{A} \mathbf{y} = \sigma \mathbf{A} \mathbf{y}$, 若 $\mathbf{A} \mathbf{y} \neq \mathbf{0} \Rightarrow \sigma = 1$, 否则 $\sigma = 0$, 因此 $\mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \mathbf{A}$ 的特征值非 0 则 1, 半正定的结论成立。 \square

对于给定的下限问题, 由不等式(15)直接得到下限为 $(\mathbf{A} \mathbf{A}^T)^{-1}$, 即

$$\text{Var}[\boldsymbol{\theta}_{\text{LSW}} - \boldsymbol{\theta}] \succcurlyeq (\mathbf{C}^T \text{Var}[\mathbf{n}] \mathbf{C})^{-1}$$

直接验证可得 $\mathbf{W} = \text{Var}^{-1}[\mathbf{n}]$ 时取等号, 此时称 \mathbf{W} 为最佳加权矩阵。